

Project

음성인식 프로젝트


AI generated music 판별 모델

Skills: (Python)Umap/MFCC/Tensorflow

빅데이터 분석 전문가 양성과정 45기

- 2조 (김민정 외 5인)

Contents



• 개요

가수의 목소리를 무단으로 사용하는
AI cover 음악을 구분하는 인공지능
모델을 개발

사용 Tool - Python (Tensorflow)

역할 - 음성데이터 전처리
- CNN 모델링

'규제 필요성이 있는 음성 Deep Fake 음악을 구별'


기여도 [80%] 팀 프로젝트 (6인)

Challenge


- ⇒ 음성 데이터 전처리(구간 분할) 및 라벨링(고유:0, AI: 1)
- ⇒ 오디오 특징 추출 전처리 기법(MFCC, GFCC)에 대해 공부 후 적용
- ⇒ 파형(waveform)으로는 구분이 어려운 오디오를 u-map 기법을 통해 시각화
- ⇒ 신경망 구축 (CNN, DNN)
- ⇒ 성능 확인




음원 데이터 수집



파형 및 umap 시각화




모델링



분류 결과 출력

1. 주제 선정 배경

'AI 음원 생산 사례 증가'



유튜브 'AI cover' 검색 결과
다량의 조회 수 발생

'관련 규제 미비'



학습 시 음원 / 목소리 무단 사용
창작자에 대한 공정한 보상 x
창작물 수집 윤리 무시

'저작권 침해 문제'




현행법상 목소리에 대한
저작권 침해 주장 성립 어려움

2. 데이터 소개


'Which one is AI?'

🎵 음원 듣기



원본



AI



차이 확인 어려움



특징추출을 umap으로
시각화하여 차이 확인

3. 음성 데이터 특징 추출

- MFCC

(Mel-Frequency Cepstral Coefficient)

디지털 변환

Framing (신호덩어리 자르기)

Windowing

(smoothing; np.hamming)

Fourier Transform

Mel Filter Bank & Log Trans.

DCT & MFCC 계산



'librosa 라이브러리'

(1) 디지털 변환

```
1 # 음성파일 읽기 & 디지털 변환 함수
2 def librosa_read_wav_files(wav_files):
3     if not isinstance(wav_files, list): # isinstance(1, int) # 1이 int형인지 알아본다. 결과는 True
4         wav_files = [wav_files]
5     return [librosa.load(f, sr = 16000)[0] for f in wav_files] # 음성파일 읽기
```

'사람의 청각 인식 기준으로 변환된 Mel spectrum으로 필터'


주파수가 높아질수록 주파수대역이 조밀하지
않다는 점을 고려한 Mel filter bank를 거치게
됩니다.



3. 음성 데이터 특징 추출

- MFCC

(Mel-Frequency Cepstral Coefficient)



```

1 # 오디오 특징 추출 함수
2 def extract_features(audio_samples, sample_rate):
3     extracted_features = np.empty((0, 101)) # (1,41) : 101개의 값을 받을 메모리를 할당
4     if not isinstance(audio_samples, list):
5         audio_samples = [audio_samples]
6
7     for sample in audio_samples:
8         zero_cross_feat = librosa.feature.zero_crossing_rate(sample).mean()
9         mfccs = librosa.feature.mfcc(y=sample, sr=sample_rate, n_mfcc=100) # 오디오에서 100개 특징 추출
10        mfccsscaled = np.mean(mfccs.T,axis=0) # 각 주파수별 평균값을 구하기
11        mfccsscaled = np.append(mfccsscaled, zero_cross_feat)
12        mfccsscaled = mfccsscaled.reshape(1, 101)
13        extracted_features = np.vstack((extracted_features, mfccsscaled))
14    return extracted_features
  
```

'librosa.feature.mfcc 내부에서는 '


프레이밍, 윈도우를 진행해 신호를 자르고, 중첩을 위해 harmonic 형태로 변환합니다.
푸리에 변환, 멜 필터링, 로그변환을 통해 신호를 정제합니다.
마지막으로 DCT (이산코사인변환)을 적용해 음성 인식에 불필요한 위상정보를 제외한
Amplitude 만으로 주파수를 **비상관화(De-correlate)**하여 주요 특징을 **벡터화**시켜
학습이 가능하도록 합니다.

이러한 매커니즘은 음악의 생성 방식을 분류하는 데 효과적일 것이라 생각하고 채택했습니다.


4. 이외의 시도

- 특징 추출 기법



'다양한 특징 추출 기법 중 계수 특징을 추출하는 전처리 기법 사용'



'MFCC vs GFCC 비교'



비선형적으로 인식하는 방식을 모방한 필터를 사용합니다.





'인간 내이의 주파수 해상도'를 모방하여 세밀한 분석이 가능합니다. 그 특성에 맞게 노이즈가 많은 환경에서 음성 특징을 추출하는 데 사용이 된다는 것을 발견했습니다. 따라서 분석의 취지에 맞는 MFCC를 채택했습니다.

5. 모델링

- 딥러닝 알고리즘

'CNN vs DNN'

Coefficient feature 추출 기법을 사용했기 때문에 1D sequence 데이터에 대해 학습할 수 있도록 1D CNN과 DNN을 적용했습니다.



합성곱과 풀링 연산이 들어간 CNN 모델에서 더욱 안정적인 성능을 보였습니다.

5. 모델링

- 상세 코드

```
1 # 신경망 구축- CNN
2 model = Sequential()
3 model.add(Conv1D(64, kernel_size=3, activation='relu', input_shape=(101,1)))
4 model.add(MaxPooling1D(pool_size=2))
5 model.add(Conv1D(128, kernel_size=3, activation='relu'))
6 model.add(MaxPooling1D(pool_size=2))
7 model.add(Conv1D(256, kernel_size=3, activation='relu'))
8 model.add(MaxPooling1D(pool_size=2))
9 model.add(Flatten())
10 model.add(Dense(64, activation='relu'))
11 model.add(Dropout(0.5))
12 model.add(Dense(1, activation='sigmoid'))
13 model.summary()
14
15 # 학습환경
16 model.compile(optimizer='adam',
17               loss='binary_crossentropy',
18               metrics=['accuracy'])
19
20
21 # val_accuracy 모니터링해서 성능이 좋아지지 않으면 조기 종료
22 early_stop = EarlyStopping(monitor='val_accuracy', verbose=1, patience=5)
23
24
25 check_point = ModelCheckpoint('best_model.h5', verbose=1,
26                               monitor='val_loss', save_best_only=True)
27
28 history = model.fit(X_train_features, y_train, epochs=50, batch_size=32, validation_data=(X_test_features,y_test), verbose=1,
29                   callbacks=[early_stop, check_point])
30
31 plt.plot(history.history['accuracy'])
32 plt.plot(history.history['val_accuracy'])
33 plt.legend(['acc', 'val_acc'])
34 plt.title('Model ACC')
35 plt.xlabel('Epochs')
36 plt.ylabel('ACC')
```

6. 고찰

한계

- 저작권 상 음성 관련 데이터 확보의 어려움이 있었습니다.
- 주어진 기간 내 음성인식 신경망 하이퍼파라미터에 대한 심도 있는 고찰의 부족이 있었습니다.

향후 발전 가능성 및 시사점

- 장르를 카테고리화하여 추가 학습으로 분석 범위를 확대할 수 있습니다.
- AI fake 음악의 구분 필요성에서 활용될 수 있습니다.
Ex) AI 워터마크 의무화 추진, 인스타그램 AI 제작 라벨
➔ Deep Fake 콘텐츠 게시 시 AI 여부 자동 판별 시스템화

감사합니다.